SEMINÁRIO · PROCESSAMENTO DE LINGUAGEM NATURAL · PPGCC/UFPA

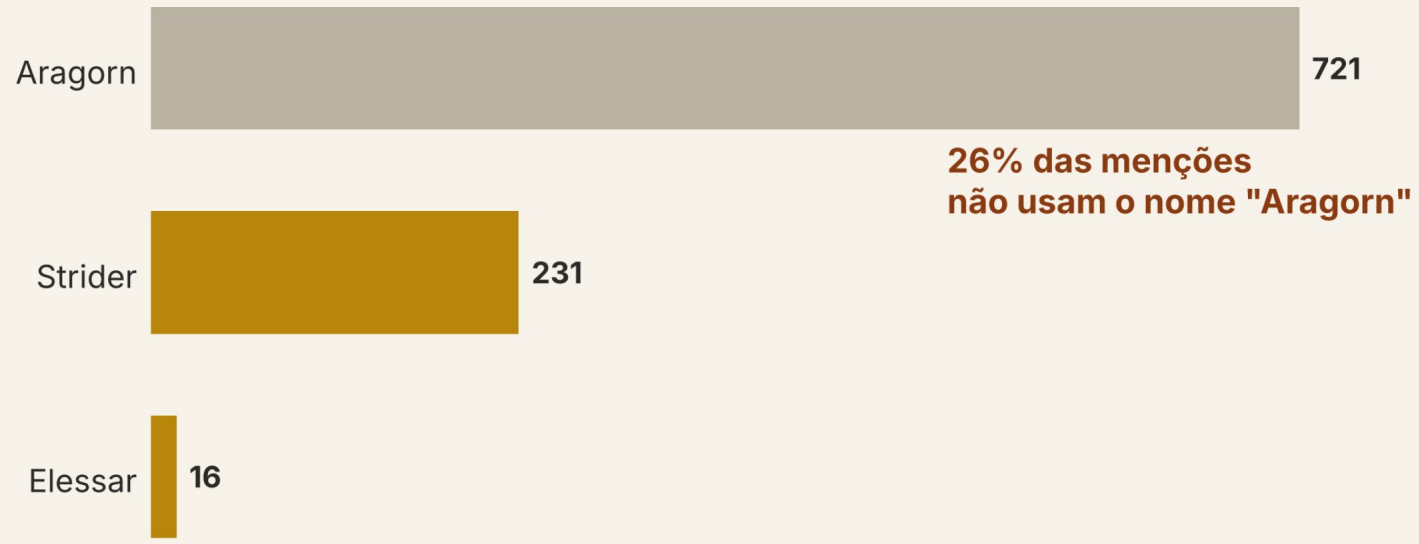
Quem é Aragorn?

Ontologias e grafos de conhecimento, testados na Terra-média

João Davi Costa Lima · Lucas Nobre Barbosa · Lizandra de Lima Quaresma · 09/11/2026

Buscar só "Aragorn" no livro deixa de fora 1 em cada 4 menções

Menções ao mesmo personagem no texto de O Senhor dos Anéis, por nome usado



Fonte: LordOfTheRingsBook.json (62 capítulos); contagem por casamento de padrões, elaboração própria

O PROBLEMA

Para a máquina, “Strider” e “Aragorn” são strings diferentes

Para o leitor são a mesma pessoa. Dizer isso de forma explícita é o primeiro trabalho de uma ontologia: 721 menções pelo nome, 231 como Passolargo, 16 como Elessar.

Cada geração de ontologias respondeu a um problema prático

séc. IV a.C.

Aristóteles, Categorias

Classificar o que existe para poder raciocinar sobre isso

1984

Cyc (Lenat)

Senso comum escrito à mão por especialistas: caro e lento

1993

Gruber

Definição de ontologia para sistemas de IA compartilharem conhecimento

2001–2004

Web Semântica e OWL

Páginas legíveis por máquinas; linguagem padronizada pelo W3C

2012

Google Knowledge Graph

Buscar entidades, não apenas sequências de texto

2024

GraphRAG

Grafos como índice para LLMs responderem sobre coleções inteiras

Toda ontologia é um tratado, um acordo social entre quem tem motivo para compartilhar (Gruber, 2004, citado por Russell e Norvig).

Taxonomia, ontologia e grafo: três níveis do mesmo mapa

Taxonomia

Organiza categorias em hierarquia.

Exemplo: Hobbit ⊂ Personagem ⊂ Ser

Ontologia

Especificação formal e explícita de uma conceitualização compartilhada (Studer et al., 1998): classes, relações e axiomas.

Exemplo: PortadorDeAnel ≡ Personagem ⊓ ∃jáPortou.AnelDePoder

Grafo de conhecimento

Fatos sobre indivíduos concretos, ligados em grafo. Com semântica formal, serve de base de conhecimento (Ji et al., 2022).

Exemplo: Frodo → portador → Posse nº 6 → anel → Um Anel

Anatomia de uma ontologia: classes, indivíduos, propriedades e axiomas

Classe

Conjunto de coisas com algo em comum.

Hobbit, **Personagem**, **Anel**

Indivíduo

Uma coisa concreta do domínio.

Frodo Baggins, **o Um Anel**

Propriedade

Relação entre indivíduos ou atributo de um indivíduo.

conjugeDe, **nascimentoAno**

Axioma

Regra que vale sempre.

Nenhum Hobbit é Anão; **conjugeDe** é simétrica

Classes, propriedades e axiomas formam o **esquema (TBox)**. Os fatos sobre indivíduos formam o **acervo (ABox)**. Juntos, compõem a base de conhecimento (Noy e McGuinness, 2001).

Os padrões por trás: RDF, RDFS, OWL e SPARQL

RDF

Tudo é tripla: sujeito, predicado, objeto.

Frodo · tipo · Hobbit

RDFS

Classes, subclasses e domínio das propriedades.

Hobbit · subclasse de · Personagem

OWL

Axiomas com semântica lógica (lógica de descrição).

Hobbit · disjunta de · Anão

SPARQL

Linguagem de consulta sobre triplas.

Quem é ancestral de Arwen?

São padrões do W3C. O arquivo da nossa ontologia está em Turtle, uma sintaxe textual de RDF, e abre no Protégé.

O que é um raciocinador

Programa que lê os axiomas e os fatos e deriva o que está implícito. Ele não aprende com exemplos: aplica regras lógicas.

Dedução

Se Hobbit ⊂ Personagem e Frodo é Hobbit, então Frodo é Personagem.

Classificação

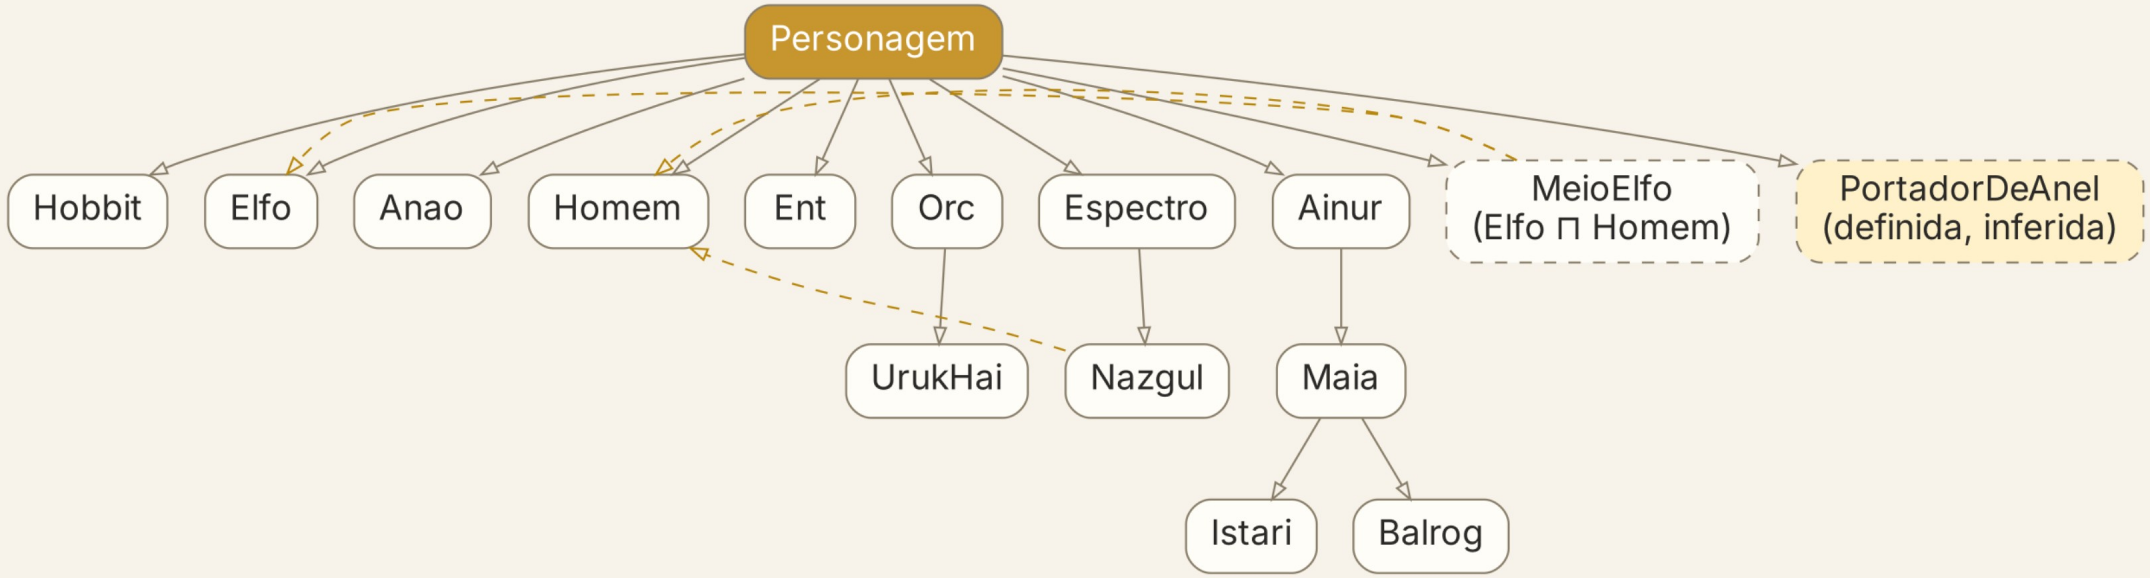
Descobre a que classes cada indivíduo pertence e como as classes se relacionam (Norvig 12.5.2).

Consistência

Detecta contradições entre axiomas e fatos.

Usamos o OWL-RL, um perfil de OWL executado por regras. Raciocinadores completos, como HermiT e Pellet, fazem mais, com custo maior.

O esquema da Terra-média: 46 classes e 19 relações



Categorias herdam

Todo Hobbit é Personagem e é Ser (Norvig 12.2).

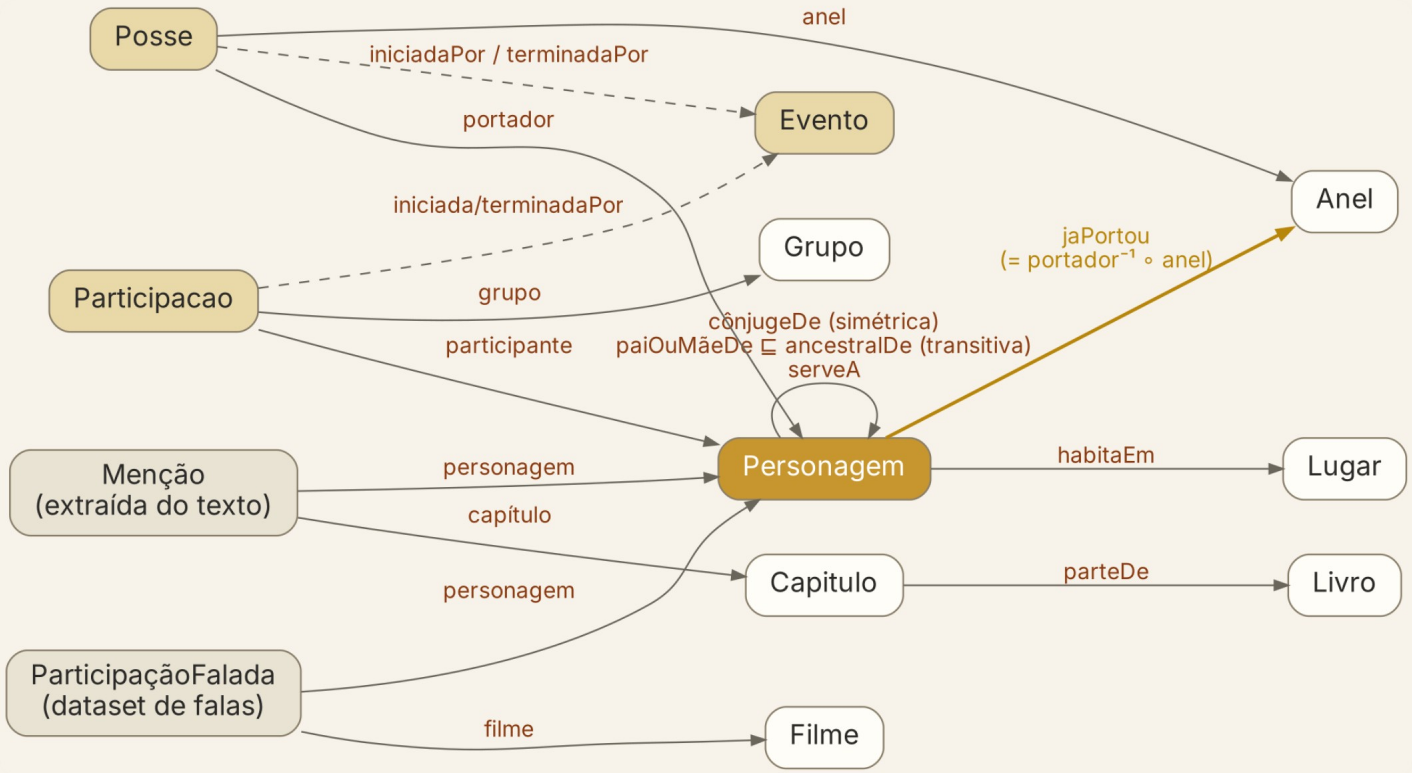
Povos são disjuntos, com exceções

Elrond é Elfo e Homem; Lúthien é Elfa e Maia. Híbridos existem.

Classe definida

PortadorDeAnel não é declarada: o raciocinador a deduz.

O tempo entra por eventos: Posse e Participação são fluentes



"Frodo é portador do Anel" não é uma verdade eterna. Vale num intervalo.

Reificamos o fato como **Posse**, com início e fim marcados por eventos: o cálculo de eventos de Norvig 12.3 (Inicia, Termina).

A relação **jáPortou** é deduzida por encadeamento de propriedades.

Mundo aberto e mundo fechado: o que a ausência de um fato significa

Mundo fechado

O que não está na base é falso. É a hipótese de SQL e de Prolog (Norvig 12.6).

Exemplo: personagem sem povo registrado ⇒ não tem povo.

Mundo aberto

O que não está na base é desconhecido. É a hipótese de OWL.

Exemplo: 140 de 911 personagens sem povo ⇒ lacuna, não inexistência.

Na web, ninguém conhece todos os fatos, e o mundo aberto é a escolha segura. O custo: menos conclusões negativas.

Quatro rotas para povoar uma ontologia; usamos três

Especialistas

Cyc, 1984

Nossa curadoria: 33 indivíduos (Anel, eventos, Sociedade).

Banco de dados

DBpedia

911 personagens, 8 filmes e 76 participações faladas.

Texto

TextRunner

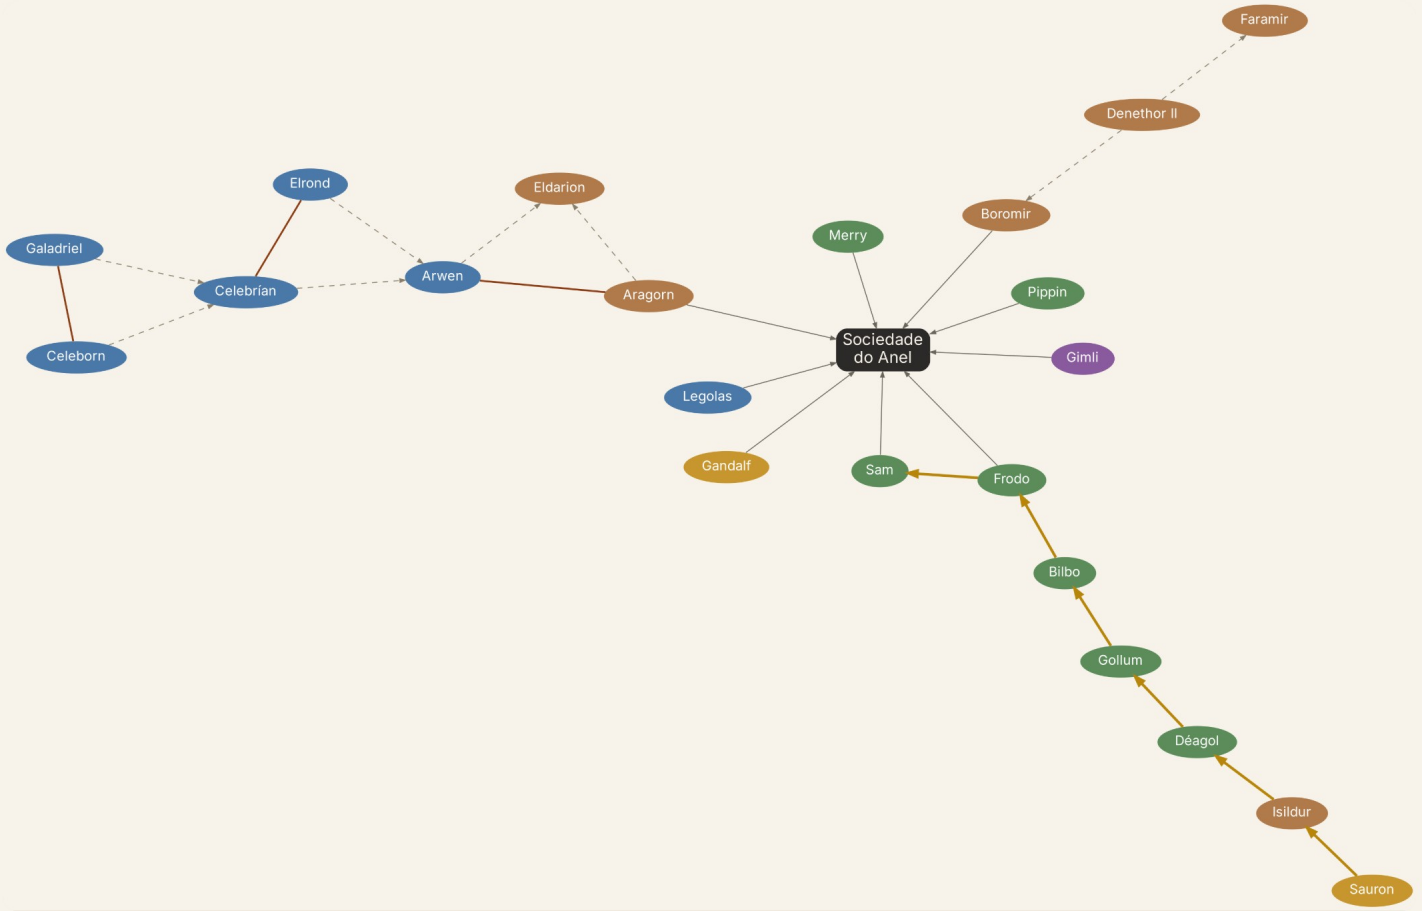
631 menções extraídas de 62 capítulos.

Voluntários

OpenMind

Não usamos.

Resultado: **12.934 triplas** em OWL/Turtle, cada afirmação com a sua proveniência (dataset, texto ou curadoria).



UMA CONSULTA, NÃO UMA BUSCA

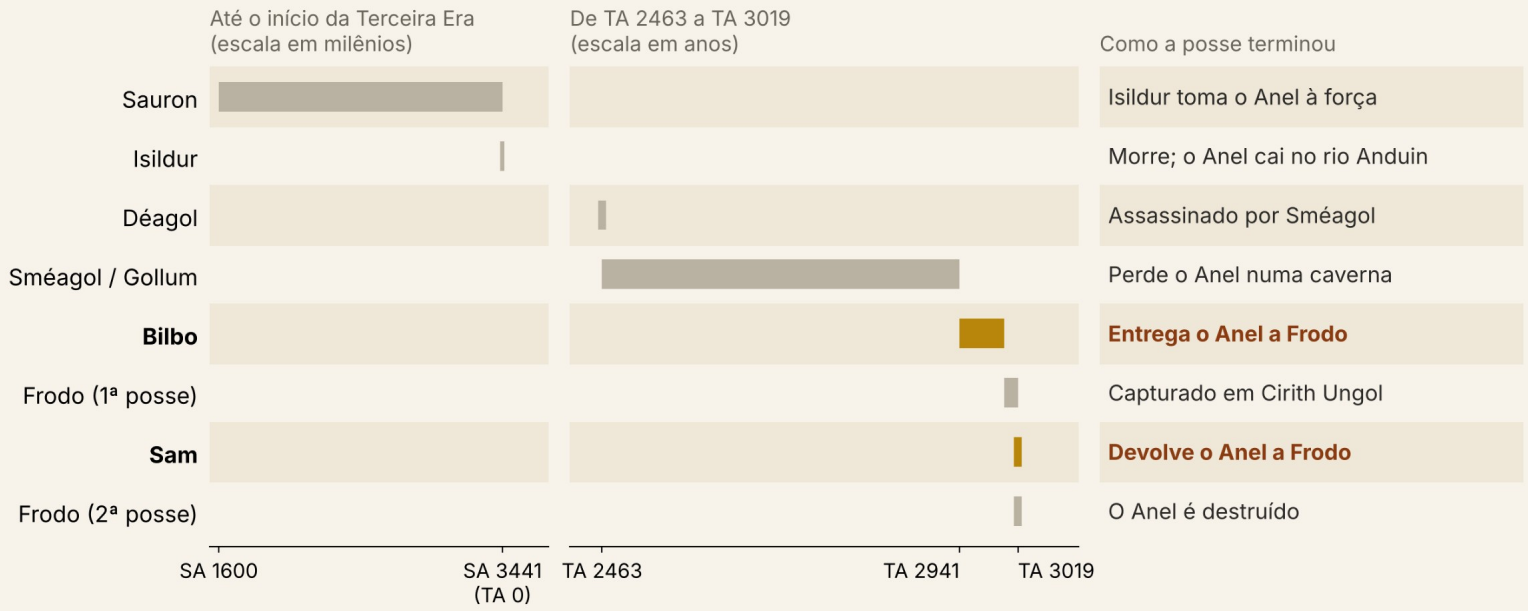
Quem teve o Anel antes de Bilbo?

Gollum, e antes dele Déagol. A resposta sai da cadeia dourada, sem depender de uma frase específica do livro.

Dourado: passagem do Anel · tracejado: pai/mãe de · marrom cheio: casamento · cor: povo

Cada posse do Anel tem início, fim e um evento que a encerra

Cada barra é um fluente Posse(portador, Anel). Em destaque: as duas posses encerradas por entrega voluntária



Fonte: curadoria a partir da obra (Apêndice B de O Senhor dos Anéis); datas aproximadas; SA = Segunda Era, TA = Terceira Era

CÁLCULO DE EVENTOS (NORVIG 12.3)

Posse é um fluente: vale entre dois eventos

Entre TA 2 e TA 2463 o Anel esteve no leito do rio Anduin: 2.461 anos sem portador conhecido. Para a ontologia, isso é lacuna, e não negação.

O raciocinador aplicado ao nosso grafo

12.934 → 26.808

Triplas antes e depois do raciocínio: as 13.874 novas ninguém digitou.

8 portadores do Anel

Nenhum foi declarado PortadorDeAnel. A definição os classificou: Isildur, Déagol, Sméagol e os demais.

4 ancestrais de Arwen

Declaramos só pai e mãe. A transitividade deduziu Elrond, Celeborn, Celebrían e Galadriel.

Uma contradição provocada

Ao afirmar que Frodo é Anão, o raciocinador acusa: Hobbit e Anão não têm indivíduos em comum.

Identidade: um nome não é um indivíduo

Vários nomes, um indivíduo

Aragorn, Passolargo, Elessar e Estel viram rótulos alternativos de um só indivíduo. Sméagol e Gollum, falantes distintos nos dados de fala, são ligados por **owl:sameAs**.

Um nome, vários indivíduos

Há três Boromir no dataset (o da Sociedade, o Regente e o da Casa de Bëor). Cada um recebe um identificador próprio.

owl:sameAs funde todos os fatos dos dois lados. Unir indivíduos por engano contamina o grafo inteiro. Em PLN, isto é correferência e ligação de entidades.

No PLN, a ontologia é o destino dos pipelines

Tarefa de PLN	O que fizemos	Papel da ontologia
Reconhecimento de entidades	Achar “Frodo” e “Passolargo” no texto	Define os tipos: Personagem, Lugar, Artefato
Ligação de entidades	Passolargo → Aragorn II Elessar	Um identificador único por indivíduo
Correferência	Sméagol = Gollum	owl:sameAs
Extração de informação	631 menções viram fatos no grafo	O esquema que recebe os fatos
Perguntas e respostas	“Quem teve o Anel antes de Bilbo?” em SPARQL	Fatos verificáveis; base para GraphRAG

Fora da Terra-média: Wikidata, Google Knowledge Graph, SNOMED CT, Gene Ontology, schema.org.

Quem escreve o tratado?

Classificar é decidir o que existe

O dataset trata Orcs como “raça”, ao lado de Hobbits. Em bases reais, categorias como raça, gênero ou ocupação são escolhas com consequências para quem é classificado.

Grafos abertos e grafos privados

A Freebase, base aberta, foi comprada pelo Google em 2010 e encerrada entre 2015 e 2016, com parte dos dados migrada para o Wikidata. O Google Knowledge Graph é proprietário: quem controla o esquema controla o que a busca trata como fato.

Terceirizar o tratado

LLMs são caixas-pretas e falham em fatos (Pan et al., 2024). Pedir a um deles que extraia o grafo entrega a decisão de classificar a um modelo que não se audita e acostuma a equipe a aceitar o que não leu.

Limites técnicos da abordagem

Curadoria não escala

Escrever axiomas à mão foi o limite do Cyc (Norvig 12.1), e grafos são difíceis de construir e evoluir (Pan et al., 2024). Aqui, 33 indivíduos foram curados à mão.

O mundo muda

Em 1951 Tolkien reescreveu o capítulo do Gollum em O Hobbit para caber na história do Anel. Revisar crenças exige lógicas não monotônicas (Norvig 12.6).

Expressividade custa

Quanto mais axiomas, mais caro raciocinar. Por isso usamos o OWL-RL, mais simples que a lógica de descrição completa.

Falta validação externa

A ontologia respondeu às nossas perguntas, mas não foi avaliada por especialistas em Tolkien.

Leituras sobre ontologias e o que cada uma trouxe

Leitura	O que trouxe para a apresentação
Russell e Norvig, Inteligência Artificial, cap. 12	Categorias, herança, fluentes e cálculo de eventos, lógicas de descrição, mundo aberto e fechado: a base da nossa modelagem.
Gruber (1993), Knowledge Acquisition 5(2)	A primeira definição: especificação explícita de uma conceitualização, para compartilhar conhecimento entre sistemas.
Studer et al. (1998), Data & Knowledge Engineering 25	A definição que usamos: formal, explícita e compartilhada, e o que cada adjetivo exige.
Guarino, Oberle e Staab (2009), Handbook on Ontologies	Como a definição evoluiu de Gruber a Borst e Studer, e por que o compartilhamento importa.
Noy e McGuinness (2001), Ontology Development 101	O método de sete passos que seguimos e a distinção entre ontologia e base de conhecimento.

Leituras sobre web, grafos e LLMs e o que cada uma trouxe

Leitura	O que trouxe para a apresentação
Berners-Lee, Hendler e Lassila (2001), Scientific American	A proposta da Web Semântica: triplas RDF e ontologias como taxonomia mais regras de inferência.
Ji et al. (2022), IEEE TNNLS 33(2)	Linha do tempo do Cyc, do RDF e da OWL ao grafo de conhecimento; relação entre grafo e base de conhecimento.
Hogan et al. (2021), ACM Computing Surveys 54(4)	Grafos de conhecimento: modelos de dados, esquema, identidade, contexto e raciocínio.
Edge et al. (2024), arXiv:2404.16130	GraphRAG vence a RAG vetorial em perguntas globais; a vetorial é mais direta nas pontuais; indexar custa caro.
Pan et al. (2024), IEEE TKDE 36(7)	LLMs são caixas-pretas e falham em fatos; grafos são difíceis de construir; como unir os dois.

Dados: transcrições do Fandom (movies.fandom.com), personagens da wiki LOTR e texto dos livros, em arquivos Kaggle. Código e ontologia (.ttl) disponíveis com a equipe.

O que levar daqui

Ontologia é uma decisão sobre o que existe, e toda decisão tem autor.

Grafo sem ontologia é pilha de fatos; ontologia sem dados é promessa.

No PLN, ela fecha o ciclo: do texto à entidade, da entidade à consulta.